



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

Bacharelado em Ciência da Computação

Diego Moreira Rocha  
Luan Barbosa Rosa Carrieros

**Projeto de Análise de Sentimentos em Redes Sociais usando  
Redes Neurais**

Belo Horizonte

2024

Diego Moreira Rocha  
Luan Barbosa Rosa Carrieiros

**Projeto de Análise de Sentimentos em Redes Sociais usando  
Redes Neurais**

Projeto de Pesquisa apresentado na disciplina Trabalho Interdisciplinar III - Pesquisa Aplicada do curso de Ciência da Computação da Pontifícia Universidade Católica de Minas Gerais.

Belo Horizonte

2024

## RESUMO

Hoje em dia, os usuários da internet estão cada vez mais interessados em expressar suas opiniões sobre uma variedade de produtos em redes sociais, o que levou ao aumento do conteúdo gerado por humanos encontrado na web. A análise de sentimentos de usuários em plataformas como o Twitter tornou-se uma tarefa essencial e desafiadora nos últimos anos. Uma técnica não convencional é necessária para realizar a tarefa de análise de sentimentos devido às características dos dados utilizados. Além disso, a análise de sentimentos em plataformas de mídia social é um tópico fundamental com várias aplicações interessantes. A maioria dos algoritmos disponíveis atualmente para classificar sentimentos nas redes sociais determina a polaridade apenas com base no conteúdo textual das postagens, ignorando informações adicionais disponíveis. Este trabalho recomenda uma arquitetura para combinar modelos CNN e Bi-LSTM. A implementação do BILCNN inclui um conceito de word embedding que transforma tweets em forma numérica, uma camada CNN que aceita embedding de atributos como fonte e gera características com critérios menores, e um modelo Bi-LSTM que recebe a entrada da camada CNN e gera resultados de classificação. Foram utilizados os embeddings GloVe e Word2Vec para determinar o efeito que a resposta de embedding de palavras teve no modelo sugerido. Os conjuntos de dados do Yelp e Tweets foram utilizados, e o BILCNN foi aplicado a eles. Os resultados indicam que o sistema proposto é capaz de fornecer sugestões com uma precisão de 94,8%, oferecendo um desempenho satisfatório para os usuários.

Palavras-chave:

Análise de Sentimentos

Redes Sociais

Redes Neurais

Aprendizado de Máquina

Bi-LSTM

CNN (Redes Neurais Convolucionais)

Processamento de Linguagem Natural (PLN)

Classificação de Texto

Dados de Mídia Social

Modelagem de Sentimentos

Deep Learning

Mineração de Dados

Sentimentos Positivos/Negativos

Análise de Dados

## SUMÁRIO

|       |                                                             |    |
|-------|-------------------------------------------------------------|----|
| 1     | INTRODUÇÃO .....                                            | 25 |
| 1.1   | Objetivos .....                                             | 25 |
| 1.1.1 | <i>Objetivos específicos</i> .....                          | 26 |
| 2     | REVISÃO BIBLIOGRÁFICA.....                                  | 27 |
| 2.1   | Fundamentação Teórica .....                                 | 27 |
| 2.1.1 | <i>Análise de Sentimentos</i> .....                         | 27 |
| 2.1.2 | <i>CNN (Convolutional Neural Network)</i> .....             | 27 |
| 2.1.3 | <i>Bi-LSTM (Bidirectional Long Short-Term Memory)</i> ..... | 28 |
| 2.1.4 | <i>Embeddings (GloVe e Word2Vec)</i> .....                  | 28 |
| 2.2   | Trabalhos Relacionados .....                                | 28 |
| 2.3   | Conclusão.....                                              | 29 |
| 3     | METODOLOGIA.....                                            | 30 |
| 3.1   | Atividades a serem realizadas .....                         | 30 |
| 3.1.1 | <i>Atividade 1: xxxx</i> .....                              | 30 |
| 3.1.2 | <i>Atividade 2: xxxx</i> .....                              | 30 |
| 3.1.3 | <i>Atividade n: xxxx</i> .....                              | 30 |
| 3.2   | Cronograma .....                                            | 30 |
| 4     | PRIMEIRO CAPÍTULO DE EXEMPLO.....                           | 31 |
| 4.1   | Primeira seção .....                                        | 31 |
| 4.1.1 | <i>Primeira subseção</i> .....                              | 32 |
| 4.2   | Segunda seção .....                                         | 32 |
| 5     | SEGUNDO CAPÍTULO DE EXEMPLO.....                            | 33 |
| 6     | OBSERVAÇÕES IMPORTANTES.....                                | 35 |
|       | REFERÊNCIAS.....                                            | 36 |

## 1 INTRODUÇÃO

Nos dias atuais, o uso crescente das redes sociais, como o Twitter, tem permitido que os usuários expressem suas opiniões sobre produtos, serviços e eventos, gerando uma quantidade massiva de dados textuais. Esse aumento de informações tornou a análise de sentimentos uma tarefa essencial e desafiadora, pois envolve a identificação e classificação automática das emoções expressas nos textos, sendo útil em aplicações como marketing digital, recomendações de produtos e análise de feedback de consumidores.

No entanto, os textos em redes sociais, como no Twitter, são curtos, muitas vezes contêm abreviações ou gírias, e apresentam variações gramaticais, o que compromete a eficiência de métodos tradicionais de análise. Além disso, muitos algoritmos focam apenas no conteúdo textual, deixando de considerar informações contextuais adicionais que poderiam melhorar a precisão dos resultados.

Para abordar essas limitações, este trabalho propõe a utilização de um modelo híbrido, que combina redes neurais convolucionais (CNN) com redes Bidirectional Long Short-Term Memory (Bi-LSTM), chamado BILCNN. A CNN extrai características locais dos textos, enquanto a Bi-LSTM captura dependências contextuais de longo alcance. Este estudo adota uma metodologia exploratória, uma vez que envolve a experimentação e avaliação de um modelo novo, buscando explorar suas capacidades e limitações na análise de sentimentos em textos curtos. Técnicas de word embedding, como GloVe e Word2Vec, são utilizadas para converter os textos em vetores numéricos.

Este trabalho está organizado da seguinte forma. A seção ?? apresenta os objetivos gerais e específicos deste projeto. O capítulo ?? aborda o referencial teórico utilizado.

### 1.1 Objetivos

O objetivo geral deste projeto é desenvolver e testar um modelo eficiente de rede neural para análise de sentimentos em redes sociais, focado especificamente em textos curtos e informais, como os encontrados no Twitter. O projeto visa combinar as forças das redes convolucionais (CNN) para extração de características locais e das redes bidirecionais de memória de longo prazo (Bi-LSTM) para capturar dependências de longo alcance,

melhorando a capacidade de generalização do modelo. O modelo proposto será avaliado com diferentes técnicas de word embedding, como GloVe e Word2Vec, a fim de preservar as relações semânticas entre as palavras, maximizando a precisão na classificação de sentimentos em contextos de alto ruído.

### ***1.1.1 Objetivos específicos***

Os objetivos específicos deste projeto são:

1. Aplicar técnicas de word embedding, como GloVe e Word2Vec, para transformar textos em vetores numéricos;
2. Integrar as arquiteturas CNN e Bi-LSTM em um modelo híbrido para análise de sentimentos;
3. Avaliar o desempenho do modelo proposto utilizando bases de dados do Twitter e Yelp, comparando com modelos tradicionais.

## 2 REVISÃO BIBLIOGRÁFICA

Este capítulo apresenta os conceitos fundamentais e os trabalhos relacionados ao uso de redes neurais para análise de sentimentos, com foco especial na integração das arquiteturas CNN e Bi-LSTM. Essas técnicas têm sido amplamente exploradas devido à sua capacidade de lidar com textos curtos e informais, como os encontrados em redes sociais.

A análise de sentimentos tem ganhado relevância na era digital, à medida que as pessoas expressam suas opiniões em plataformas como o Twitter e o Yelp. A combinação de redes neurais convolucionais (CNN) e redes do tipo Bi-LSTM mostrou-se uma abordagem promissora para superar os desafios associados a essa tarefa, especialmente em textos de natureza não estruturada.

“A análise de sentimentos em plataformas de redes sociais, como o Twitter, tem se tornado uma tarefa fundamental, especialmente devido à natureza breve e informal das mensagens, que muitas vezes contêm gírias, abreviações e variações gramaticais. Técnicas tradicionais de análise de sentimentos, que se baseiam exclusivamente no conteúdo textual, podem falhar em captar nuances importantes, resultando em classificações imprecisas” (MANIKANDAN; CHAKARAVARTHI, 2022).

### 2.1 Fundamentação Teórica

#### 2.1.1 *Análise de Sentimentos*

Técnica de Processamento de Linguagem Natural (PLN) usada para identificar a polaridade (positiva, negativa ou neutra) em textos.

#### 2.1.2 *CNN (Convolutional Neural Network)*

Rede neural especializada na detecção de padrões em dados, extraindo características locais de textos, como frases ou palavras.

### 2.1.3 *Bi-LSTM (Bidirectional Long Short-Term Memory)*

Variante de rede recorrente que processa dados em duas direções, capturando dependências contextuais de longo alcance.

### 2.1.4 *Embeddings (GloVe e Word2Vec)*

Representação vetorial das palavras, que preserva relações semânticas, facilitando a análise de sentimentos.

A aplicação de redes neurais na análise de sentimentos evoluiu significativamente com o uso de arquiteturas como CNN e Bi-LSTM. A CNN é comumente utilizada para extrair características locais de um texto, identificando padrões relevantes que auxiliam na classificação de sentimentos. A Bi-LSTM, por sua vez, captura dependências de longo alcance ao processar as palavras em ambas as direções (frente e verso), o que permite uma análise mais completa e contextual.

Estudos recentes demonstram que a combinação dessas arquiteturas resulta em um modelo mais robusto, capaz de lidar com a complexidade dos textos gerados em redes sociais, oferecendo melhor desempenho na tarefa de análise de sentimentos.

## 2.2 Trabalhos Relacionados

Diversos trabalhos têm explorado a integração de CNN e Bi-LSTM para a análise de sentimentos. Rhanoui et al. (2019) propuseram um modelo de CNN-BiLSTM para a análise de sentimentos em nível de documento. Neste estudo, foi utilizado o Doc2Vec para representar documentos longos, como artigos de jornal. A abordagem combinada de CNN e Bi-LSTM permitiu capturar características locais e contextuais das frases e melhorar a precisão da classificação de sentimentos, especialmente em textos extensos. O modelo obteve uma precisão de 90,66%, superando outras abordagens de CNN e LSTM puras.

Já Manikandan e Chakaravarthi (2022) propuseram o modelo BILCNN, aplicando-o à análise de sentimentos em textos curtos de redes sociais. O uso de embeddings como GloVe e Word2Vec ajudou a capturar as características locais e contextuais das frases, oferecendo melhor desempenho na classificação de sentimentos, especialmente em cenários de alto ruído, como o Twitter.

“A combinação de CNN e Bi-LSTM provou ser uma abordagem eficaz para a classificação de sentimentos, superando modelos tradicionais em termos de precisão e capacidade de generalização em textos curtos e informais” (SHANLIANG et al., 2018).



## 2.3 Conclusão

Os modelos híbridos que combinam CNN e Bi-LSTM têm se mostrado eficazes na análise de sentimentos, especialmente em textos curtos e não estruturados, como aqueles encontrados em redes sociais. A utilização de técnicas de word embedding, como GloVe e Word2Vec, contribui para o sucesso desses modelos ao transformar palavras em representações numéricas mais adequadas para a tarefa de classificação.

3 METODOLOGIA

Este capítulo .... Apresentar uma classificação da pesquisa.

3.1 Atividades a serem realizadas

Esta seção apresenta ....

3.1.1 *Atividade 1: xxxx*

Descrição

3.1.2 *Atividade 2: xxxx*

Descrição

3.1.3 *Atividade n: xxxx*

Descrição

3.2 Cronograma

Esta seção apresenta ... (Tabela 1).

Tabela 1 – Cronograma

|                 | Meses<br>1-3 | Meses<br>4-6 | Meses<br>7-9 | Meses<br>10-11 |
|-----------------|--------------|--------------|--------------|----------------|
| Pesquisa asdads | X            | X            |              |                |
| Coleta de dados |              | X            | X            |                |
| sdfsdf          | X            |              | X            | X              |
| nova linha      | X            |              | X            | X              |

## 4 PRIMEIRO CAPÍTULO DE EXEMPLO

A seguir serão apresentados alguns comandos do LaTeX usados comumente para formatar textos de dissertação baseados na normalização da PUC (2011).

Para as citações a norma estabelece duas formas de apresentação. A primeira delas é empregada quando a citação aparece no final de um parágrafo. Neste caso, o comando `cite` é usado para formatar a citação em caixa alta, como é mostrado no exemplo a seguir. (??).

Outra forma de apresentação da citação é a que ocorre no decorrer do texto, essa situação é exemplificada na próxima frase. Conforme ??), o estudo mencionado revela progressos no desempenho dos processadores. Para a formatação da citação em caixa baixa deve ser usado o comando `citeonline`.

Nas citações que aparecem mais de uma referência as mesmas devem ser separadas por vírgulas, como neste exemplo. (?????). Se houver necessidade de especificar a página ou que foi realizada uma tradução do texto deve ser feito da seguinte maneira. (??, p. 2, tradução nossa). A citação direta deve ser feita de forma semelhante. “[...] A carga de trabalho de um sistema pode ser definida como o conjunto de todas as informações de entrada.” (??, p. 160).

O arquivo `dissertacao.bib` mostra exemplos de representação para vários tipos de referências (artigos de conferências, periódicos, relatórios, livros, dentre outros). Cada um desses tipos requer uma forma diferente de representação para que a referência seja formatada conforme as exigências da normalização.

### 4.1 Primeira seção

Para gerar a lista de siglas automaticamente deve ser usado o pacote *acronym*. Para tanto, toda vez que uma sigla for mencionada no texto deve ser usado o comando `ac{sigla}`. Dessa forma, se for a primeira ocorrência da sigla a mesma será escrita por extenso conforme descrição feita no arquivo `lista-siglas.tex`. Caso contrário, somente a sigla será mostrada. Ex

#### **4.1.1 Primeira subseção**

As enumerações devem ser geradas usando o pacote *compactitem*. Cada item deve terminar com um ponto final. Abaixo um exemplo de enumeração é apresentado:

- a) Coletar e analisar.
- b) Configurar e simular.
- c) Definir a metodologia.
- d) Avaliar o desempenho.
- e) Analisar e avaliar características.


#### **4.2 Segunda seção**

Para referenciar um capítulo, seção ou subseção basta definir um label para o mesmo e usar o comando `ref` para referenciá-lo no texto. Exemplo: Como pode ser visto no Capítulo 4 ou na Seção 4.1.

## 5 SEGUNDO CAPÍTULO DE EXEMPLO

As figuras devem ser apresentadas pelos comandos abaixo. O parâmetro *width* determina o tamanho que a figura será exibida. No parâmetro *caption* o texto que aparece entre colchetes será o exibido no índice de figuras e o texto contido entre chaves será exibido na legenda da figura. Para citar a figura o comando *ref* deve ser usado juntamente com o *label*, como é mostrado nesse exemplo da Figura 1.


**Figura 1 – Principais componentes de WiNoCs**



**Fonte: (??)**

Os comandos abaixo são usados para apresentação de gráficos. A diferença está apenas na definição do tipo “grafico” que permite a adição dos itens no índice de gráficos de forma automática. Os parâmetros são semelhantes aos usados para representação de figuras. O parâmetro *width* determina o tamanho do gráfico. O texto entre colchetes no *caption* será o exibido no índice de gráficos e o texto contido entre chaves será exibido na legenda.

Gráfico 1 – Percentual de pacotes enviados



Fonte: Dados da pesquisa

Um exemplo de criação de tabela é mostrado a seguir. As colunas são separadas por elementos & e as linhas por duas barras invertidas. Os comandos *hline* e *|* definem a criação de linhas e colunas para separar os conteúdos, respectivamente. A tabela pode ser referenciada usando o comando *ref* juntamente com o label, como na Tabela 2.

Tabela 2 – Parâmetros definidos por classe

| <i>Benchmark</i> | Parâmetro   | Classe S | Classe W     | Classe A      | Classe B      | Classe C | Classe D        |
|------------------|-------------|----------|--------------|---------------|---------------|----------|-----------------|
| BT               | <i>Grid</i> | $12^3$   | $24^3$       | $64^3$        | $102^3$       | $162^3$  | $408^3$         |
| CG               | Linhas      | 1400     | 7000         | 14000         | 75000         | 150000   | 1500000         |
| EP               | Pares       | $2^{24}$ | $2^{25}$     | $2^{28}$      | $2^{30}$      | $2^{32}$ | $2^{36}$        |
| FT               | <i>Grid</i> | $64^3$   | $128^2 * 32$ | $256^2 * 128$ | $512 * 256^2$ | $512^3$  | $2048 * 1024^2$ |
| IS               | Chaves      | $2^{16}$ | $2^{20}$     | $2^{23}$      | $2^{25}$      | $2^{27}$ | $2^{31}$        |
| LU               | <i>Grid</i> | $12^3$   | $33^3$       | $64^3$        | $102^3$       | $162^3$  | $408^3$         |
| MG               | <i>Grid</i> | $32^3$   | $128^3$      | $256^3$       | $256^3$       | $512^3$  | $1024^3$        |
| SP               | <i>Grid</i> | $12^3$   | $36^3$       | $64^3$        | $102^3$       | $162^3$  | $408^3$         |

Fonte: Adaptado de (??)

## 6 OBSERVAÇÕES IMPORTANTES

Este documento foi compilado em ambiente linux (Ubuntu 10.04) usando o programa Kile - an Integrated LaTeX Environment - Version 2.0.85. Para correta formatação os seguintes arquivos do pacote *abntex* devem ser alterados.

a) Arquivo abnt.cls

No Ubuntu o arquivo fica armazenado em */usr/share/texmf/tex/latex/abntex*. Comentar a linha 967: Linha comentada para reduzir o espaçamento entre o topo da página e o título. Alterar a linha 1143: Parâmetro alterado de 30pt para -30pt para reduzir o espaçamento entre o top da página e o título do apêndice. Alterar a linha 985: Parâmetro alterado de 0pt para -30pt para reduzir o espaçamento entre o top da página e o título. Alterar a linha 991: Parâmetro alterado de 45pt para 30pt para reduzir o espaçamento entre o texto e o título.

b) Arquivo acronym.sty

No Ubuntu o arquivo fica armazenado em */usr/share/texmf-texlive/tex/latex/acronym*. Alterar a linha 225: Inserir o separador – entre acrônimo/descrição e remover o negrito com o *normalfont*.

## REFERÊNCIAS